

INSTYTUT CHEMII BIOORGANICZNEJ PAN
ANALIZA DANYCH snRNA-SEQ

EBF2 jako marker do rozdziału jąder Purkinjego

Dwa twierdzenia i ich weryfikacja

Analiza
Mikołaj RURAD

5 września 2026

SPIS TREŚCI

1	Dane	1
1.1	Skąd pochodzą dane	1
1.2	Kod	1
2	Twierdzenie pierwsze	2
2.1	Treść twierdzenia	2
2.2	Jak to policzyłem	2
2.3	Wyniki	2
2.4	Cztery próby obalenia twierdzenia	2
2.5	Ograniczenie, o którym trzeba wiedzieć	3
3	Twierdzenie drugie	4
3.1	Treść twierdzenia	4
3.2	Białko EBF2	4
3.3	Dlaczego akurat ten fragment białka	5
3.4	Czego można się spodziewać na cytometrze	5
3.5	Trzy powody, dla których w rzeczywistości będzie gorzej	6
4	Podsumowanie	7

1 DANE

1.1 SKĄD POCHODZĄ DANE

Atlas mózdzku myszy. Kozareva V. i wsp., *A transcriptomic atlas of mouse cerebellar cortex comprehensively defines cell types*, *Nature* 2021; 598(7879): 214–219. Numer akcesyjny GEO: **GSE165371**.

- <https://www.ncbi.nlm.nih.gov/geo/query/acc.cgi?acc=GSE165371>
- DOI: <https://doi.org/10.1038/s41586-021-03220-z>
- Kod autorów: <https://github.com/MacoskoLab/cerebellum-atlas-analysis>

Metoda: snRNA-seq, 10x Chromium V3, jądra z kory mózdzku dorosłej myszy, 16 płacików. Macierz zawiera **24 409 genów** i **611 034 jąder** po kontroli jakości. Komórek Purkiniego jest **16 634**, podzielonych przez autorów na 9 podtypów: siedem oznaczonych jako Aldoc dodatnie (10 427 jąder) i dwa jako Aldoc ujemne (6 207 jąder).

Białko EBF2.

- UniProt (mysz, 008792): <https://www.uniprot.org/uniprotkb/008792/entry>
- Model przestrzenny AlphaFold: <https://alphafold.ebi.ac.uk/entry/008792>
- Praca wiążąca EBF2 z zebriną (Chung i wsp. 2008): <https://pubmed.ncbi.nlm.nih.gov/18403128/>

Przeciwciała przeciw EBF2.

- R&D Systems AF7006, owcze, reaktywność z myszą zadeklarowana: https://www.rndsystems.com/products/human-mouse-ebf-2-antibody_af7006
- Wersje sprzężone z barwnikiem: AF7006P (PE) oraz AF7006J (Janelia Fluor 646)
- Atlas Antibodies HPA003954 i HPA055101: <https://www.proteinatlas.org/ENSG00000221818-EBF2/antibody>

1.2 KOD

Wszystkie liczby w tym dokumencie pochodzą z policzonych skryptów. Repozytorium:

<https://github.com/mikolajrura/pc-zebrin-sorting>

Odnosińki do poszczególnych skryptów w dalszej części dokumentu wskazują pliki w katalogu scripts/ tego repozytorium. Repozytorium jest prywatne, więc wymaga nadania dostępu.

2 TWIERDZENIE PIERWSZE

2.1 TREŚĆ TWIERDZENIA

Komórki Purkinjego oznaczone przez Kozarevą jako Aldoc dodatnie i Aldoc ujemne różnią się ilością mRNA genu *Ebf2*. Grupa Aldoc ujemna ma go wyraźnie więcej.

2.2 JAK TO POLICZYŁEM

Krok 1, pobranie. Z GEO pobrano trzy pliki: macierz `cb_adult_mouse.mtx.gz` (3,1 GB), listę 611 034 kodów kreskowych i listę 24 409 nazw genów. Z repozytorium autorów pobrano tabelę metadanych z przypisaniem każdego jądra do typu komórki i podtypu.

Krok 2, przygotowanie. Skrypt `00_prep_map.py` łączy kody kreskowe z metadanymi. Jest tu pułapka, którą trzeba było obejść: dwanaście próbek ma inną nazwę w GEO niż w metadanych autorów, na przykład `VI2a_F002` kontra `DECa_F002`. Naiwne połączenie gubi 1 167 komórek Purkinjego, czyli 7 procent, w tym trzy czwarte jąder z płacika Culmen. Skrypt stosuje mapowanie nazw przed połączeniem.

Skrypt `01_extract.sh` wycina z dużej macierzy tylko kolumny odpowiadające komórkom Purkinjego, czytając plik strumieniowo. Cała macierz nie mieści się w pamięci tej stacji roboczej.

Skrypt `02_build_h5ad.py` składa wynik w plik `purkinje_cells_v2.h5ad` o wymiarach 16 634 na 24 409 i sprawdza go: dla 16 538 z 16 634 komórek liczba niezerowych genów zgadza się z metadanymi co do jedności. Etykieta Aldoc dodatni lub ujemny bierze się **wyłącznie z nazwy podtypu nadanej przez autorów pracy**, nie z żadnego progu ustawionego przeze mnie.

Krok 3, wynik. Zliczenia znormalizowano do 10 000 na jądro (jednostka CP10K) i porównano obie grupy.

2.3 WYNIKI

Zdolność rozdzielająca, mierzona polem pod krzywą ROC, wynosi **0,932** dla wartości znormalizowanych i **0,916** dla surowych zliczeń.

2.4 CZTERY PRÓBY OBALENIA TWIERDZENIA

Każdy z poniższych testów mógł twierdzenie unieważnić. Żaden tego nie zrobił.

1. **Czy to efekt próbki, a nie fenotypu?** Porównano obie grupy *wewnątrz każdej próbki osobno*. W **57 na 57** próbek mających co najmniej 10 jąder w obu grupach, grupa Aldoc ujemna ma wyższy poziom *Ebf2*. Test kolejności par: $p = 5,1$ na 10 do minus jedenastej.

	Aldoc dodatnie (n = 10 427)	Aldoc ujemne (n = 6 207)
Średnia <i>Ebf2</i> (CP10K)	1,163	6,347
Mediana <i>Ebf2</i> (CP10K)	0,293	5,942
Jąder bez odczytu	47,4 %	0,9 %
Mediana surowych zliczeń	1	14

Tabela 2.1. Poziom mRNA *Ebf2* w obu grupach. Skrypt 44_audyt_ebf2.py.

2. **Czy to efekt położenia w mózdzku?** Rozdział sprawdzono osobno w każdym płaciku. Działa we **wszystkich 14** płacikach mających obie grupy, z polem pod krzywą od 0,672 do 0,960, mediana 0,887.
3. **Czy to efekt głębokości sekwencjonowania?** Podzielono jądra na cztery grupy według liczby odczytów. Zdolność rozdzielająca jest stabilna: 0,906, 0,934, 0,947 i 0,944.
4. **Czy to błąd w moim kodzie?** Ten sam wynik policzono drugą, niezależną drogą: prosto z surowego pliku macierzy, z pominięciem całego potoku przetwarzania. Największa różnica między dwiema drogami wyniosła **0,000002** jednostki CP10K.

2.5 OGRANICZENIE, O KTÓRYM TRZEBA WIEDZIEĆ

Podział na Aldoc dodatnie i ujemne to nazwy grup nadane przez autorów pracy po pogrupowaniu komórek na podstawie całego transkryptomu. Wewnątrz grup skrajnych poziom *Ebf2* nie zmienia się razem z poziomem *Aldoc*: w podtypie Aldoc_1 współczynnik korelacji wynosi 0,005, a w Anti_Aldoc_1 minus 0,014. Zależność widać dopiero w podtypach pośrednich, od minus 0,22 do minus 0,42.

Poprawne sformułowanie brzmi więc: **grupy Aldoc dodatnia i ujemna różnią się poziomem EBF2**. Nie należy mówić, że poziom EBF2 przewiduje poziom Aldoc w pojedynczej komórce.

3 TWIERDZENIE DRUGIE


3.1 TREŚĆ TWIERDZENIA

Jeżeli wybarwić jądra przeciwciałem przeciw EBF2 i na wykresie punktowym SSC kontra sygnał przeciwciała spojrzeć na bramkę R3, to jądra Aldoc ujemne przesuną się w prawo, ponieważ mają więcej EBF2.

To jest **przewidywanie, nie wynik pomiaru**. Opiera się na mRNA, a nie na zmierzonym białku.

3.2 BIAŁKO EBF2

EBF2 (008792), czynnik transkrypcyjny z rodziny COE, 575 aminokwasów, masa 62 606 Da. Struktury doświadczalnej nie ma: w bazie PDB nie ma ani jednego wpisu dla EBF2 myszy ani człowieka. Poniższa rycina to model przewidziany przez AlphaFold.



Rysunek 3.1. Model AlphaFold białka EBF2 myszy. Kolor niebieski, domena wiążąca DNA (reszty 34 do 244). Zielony, domena IPT/TIG (253 do 336). Szary w środku, trzy helisy odpowiadające za łączenie się białek w pary (337 do 412). **Pomarańczowy, fragment rozpoznawany przez przeciwciało** (413 do 550), kolor żółty to jego rdzeń (496 do 528). Rycina wykonana skryptem 45_fig_epitop_czarne.pml.

3.3 DLACZEGO AKURAT TEN FRAGMENT BIAŁKA

W komórkach Purkiniego jest też białko pokrewne, EBF1. Jest go **sześć i pół raza więcej** niż EBF2 (20,5 kontra 3,1 CP10K) i jest obecne w 99,9 procentach jąder, przy czym **nie różnicuje** grup Aldoc. Przeciwciało, które myliłoby oba białka, zniósłoby cały rozdział.

Porównanie sekwencji obu białek pokazuje, gdzie da się je odróżnić:


Obszar białka	Podobieństwo EBF2 do EBF1
Domena wiążąca DNA	95,5 %
Domena IPT/TIG	96,4 %
Koniec C (413 do 550)	62,2 %

Tabela 3.1. Odróżnić je można tylko na końcu C. Skrypt 39_ebf2_struktura_fig.py.

Przeciwciało HPA003954 rozpoznaje fragment 412 do 550, czyli dokładnie ten obszar. Sprawdzono dopasowanie tego fragmentu do białek myszy: **100 procent zgodności z mysim EBF2** (138 na 138 reszt), 60,3 procent z EBF1 i 71,8 procent z EBF3.

Ten fragment nie ma własnej struktury przestrzennej. Spośród 138 reszt **żadna** nie osiąga progu wiarygodności modelu. To dobrze dla przeciwciała: fragment sterczy na zewnątrz i jest dostępny bez dodatkowej obróbki próbki.

3.4 CZEGO MOŻNA SIĘ SPODZIEWAĆ NA CYTOMETRZE



Rysunek 3.2. Symulacja wykresu punktowego dla bramki R3 przy 3 152 zdarzeniach, czyli tylu, ile było w próbce cerebellum-1-test. Kolory pokazują prawdę, której na cytometrze nie widać. Czarny obrys po prawej to wszystko, co widzi aparat. Skrypt 43_symulacja_bramki_ebf2.py.

Wniosek jest taki: **nie zobaczy się dwóch osobnych skupisk**. Będzie jedno skupisko rozciągnięte wzdłuż osi sygnału, z zagęszczeniem przy dolnej krawędzi. Granicę bramki trzeba będzie ustawić umownie, a nie w naturalnym przewężeniu.

Przy najlepszym możliwym progu czystość wyniesie:

Bramka	Liczba jąder	Czystość
Sygnał niski, czyli Aldoc dodatnie	1 724	94,5 %
Sygnał wysoki, czyli Aldoc ujemne	1 428	73,5 %

Tabela 3.2. Symulacja przy 3 152 zdarzeniach.

3.5 TRZY POWODY, DLA KTÓRYCH W RZECZYWISTOŚCI BĘDZIE GORZEJ

1. Te 47 procent jąder Aldoc dodatnich bez odczytu to w dużej części ograniczenie metody snRNA-seq, a nie faktyczny brak białka. Zera sztucznie rozsuwają obie grupy.
2. Białko utrzymuje się w komórce dłużej niż mRNA, więc uśrednia różnice.
3. Przeciwniało daje tło, którego w danych o mRNA nie ma wcale.

Wartość 0,932 należy więc traktować jako **górną granicę**, a nie jako przewidywany wynik.

4 PODSUMOWANIE

- Twierdzenie pierwsze jest **potwierdzone** i przeszło cztery próby obalenia. Różnica w poziomie mRNA *Ebf2* między grupami jest duża i nie wynika z próbki, położenia w mózdzku, głębokości odczytu ani błędu w kodzie.
- Twierdzenie drugie to **przewidywanie**. Kierunek przesunięcia jest niemal pewny, ale rozdział będzie stopniowy, a nie dwuskupiskowy.
- **Nikt dotąd nie zmierzył białka EBF2 w tych komórkach cytometrycznie.** Żadne z dostępnych przeciwciał nie ma potwierdzenia do cytometrii przepływowej.
- Do pierwszego podejścia warto wziąć przeciwciało AF7006 bez barwnika wraz z przeciwciałem drugorzędowym, ponieważ daje ono wzmocnienie sygnału. Jest owcze, więc nie koliduje z mysim przeciwciałem przeciw RanBP2 zajmującym kanał 488.
- Konieczna jest kontrola bez przeciwciała przeciw EBF2. Bez niej, wobec braku naturalnego przewężenia, granica bramki byłaby dowolna.